# **Contents**

1	Intr	oduzione	3				
2	MLI		4				
	2.1	MLE di una Bernoulliana	5				
	2.2	MLE di una Poisson	6				
	2.3	MLE distribuzione Uniforme	7				
	2.4	MLE distribuzione Normale	7				
3	Inte	Intervalli di confidenza					
	3.1	$\mu$ incognita e varianza $\sigma^2$ nota	8				
	3.2	$\mu$ incognita e varianza $\sigma^2$ incognita	9				
	3.3	Metodo Montecarlo	10				
4	Intervalli di predizione 1						
	4.1	$\mu$ incognita e varianza $\sigma^2$ incognita	11				
	4.2	Intervalli di confidenza per la varianza	12				
	4.3	Stime per la differenza tra le medie di due popolazioni normali	13				
5	Inte	rvalli di confidenza	16				
	5.1	Intervalli approssimati per Bernoulli	16				
	5.2	Qualità ed efficienza degli stimatori	17				
		5.2.1 Bias e Polarizzazione	17				
		5.2.2 Combinazioni di stimatori corretti	18				
	5.3	Stimatore della media di una distribuzione uniforme	20				
6	Stin	natori Bayesiani	22				
		Stimatore di $\theta$ per Bernoulli	24				
	6.2	Stimatore di $ heta$ per una Normale	25				
	6.3	Stimatore di $\theta$ per Uniformi	26				

7	Veri	Verifica delle ipotesi								
	7.1	Livelli di significatività								
	7.2	Verifica di ipotesi sulla media di una popolazione normale 27								
	7.3	Test unilaterali								
	7.4	ll test t								
	7.5	Verifica se due popolazioni hanno la stessa media								
	7.6	Intervalli di confidenza (Unilaterali)								
	7.7	Esempio:								
	7.8	Intervallo di confidenza								
	7.9	Intervallo di confidenza nella varianza								
	7.10									
	7.11									
	7.12	Qualità di uno stimatore								
		Proprietà di uno stimatore								
		Stimatore unbaieseo								
		Valutazione di uno stimatore								
		Esempio:								
8	Test	st di ipotesi 4								
	8.1	Metolodogia alternativa								
	8.2	Test di Hp unilaterale								
	8.3	Test di ipotesi								
	8.4	Uguaglianza media di due popolazioni								
	8.5	Modelli previsionali								
		8.5.1 Modelli di regressione previsionale								
		8.5.2 Regressione lineare								
		8.5.3 Regressione Lineare (e non)								

## 1 Introduzione

In probabilità quello che facciamo noi è quello di supporre che le nostre distribuzioni siano **note**.

in statistica facciamo il contrario, ossia dire qualcosa (anche detto *fare dell'inferenza*) su **parametri sconosciuti**.

Dato che i parametri sono scimage pngonosciuti il massimo che possiamo fare è quello di ottenere una stima dei parametri incogniti.

Codesti signorini sono chiamati **stimatori puntuali** e sono indicati con il simbolo  $\hat{\theta}$  (in questo caso stiamo parlando di uno stimatore del parametro incognito  $\theta$ )

Esisono anche gli *stimatori non puntuali*, noti come **intervalli di confidenza**, ossia un intervallo di valori in cui può essere contenuto il *dato incognito*.

# **Esempio** $\hat{\theta}$ ? Altezza della popolazione

$$X_1 = 1.7$$
  $X_2 = 1.82$   $X_3 = 1.73$   $X_4 = 1.7$ 

### Possibile soluzione

$$\hat{\theta_a} = \frac{1}{n} \sum_{4}^{5} x_i = \frac{1.7 + 1.82 + 1.73 + 1.7 + 1.8}{5} = \frac{8.75}{5} = 1.75$$

$$\hat{\theta_b} = \frac{\min(x_i) + \max(x_i)}{2} = \frac{3.52}{2} = 1.76$$

$$\hat{\theta_c} = \frac{1}{3} \sum_{2}^{4} x_i = \frac{1}{3} (1.8 + 1.73 + 1.7) = \frac{5.23}{3} = 1.743$$

Scartiamo il più piccolo e il massimo, calcolando poi la media dei rimanenti

## 2 MLE

**Definizione:** Stima a Massima Verosomiglianza (Maximum Likelihood Estimation)

Questa classe di stimatori sono molto usati in statistica, servono per determinare i migliori parametri del modello che si adattano ai dati e comparare molteplici modelli per *determinare* quello che si adatta di più ai dati.

Ad esempio la stima di massima verosomiglianza  $\hat{\theta}$  è definita come il valore di  $\theta$  che rende massima  $f(x_1, x_2, \ldots, x_n | \theta) \to$  anche detta funziona di likelihood

**Likelihood**: avendo dei dati quale è la probabilità che un certo modello descriva al meglio la natura dei nostri dati

$$\hat{\theta} = argmaxL(\theta) = argmax[f(X_1 \dots X_n/\theta)]$$

Stima parametrica (Point) Parametric Estimation

Formula generica: Bayes

$$P(\theta/X_1 \dots X_n) = \frac{P(X_1 \dots X_n/\theta)P(\theta)}{P(X_1 \dots X_n)}$$

Verosomiglianza (likelihood)

### 2.1 MLE di una Bernoulliana

Vengono realizzate n prove indipendenti con probabilità p di successo

$$X_i = \begin{cases} 1 & \text{se la prova i-esima ha successo} \\ 0 & \text{altrimenti} \end{cases}$$

La distribuzione dell  $X_i$  è la seguente:

$$P(X_i = k) = p^k (1 - p)^{1 - k}, \qquad k \in \{0, 1\}$$

La likelihood (ossia la funzione di massa congiunta) è:

$$f(x_1, x_2, \dots, x_n | p) := P(X_1 = x_1, X_2 = x_2, \dots X_n = x_n | p)$$

$$= p^{x_1} (1 - p)^{1 - x_1} \dots p^{x_n} (1 - p)^{1 - x_n}$$

$$= p^{\sum_i x_1} (1 - p)^{n - \sum_i x_1} \qquad x_1 = 0, 1 \qquad i = 1, \dots, n$$

Possiamo derivare rispetto a p:

$$\frac{d}{dp}\log f(x_1, x_2, \dots, x_n | p) = \frac{1}{p} \sum_{i=1}^n x_i - \frac{1}{1-p} \left( n - \sum_{i=1}^n x_i \right)$$

Da questo bro possiamo ottenere un'espressione per la stima  $\hat{p}$ :

$$\hat{p} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

## 2.2 MLE di una Poisson

La funzione di *likelihood* è data da:

$$f(x_1, x_2 \dots x_n/\lambda) = \frac{\lambda^{x_1} e^{-y}}{x_1!} \dots \frac{\lambda^{x_n} e^{-\lambda}}{x_n!}$$
$$= \frac{\lambda^{\sum_i x_i} e^{-\lambda}}{x_1! \dots x_n!}$$

Come sempre deriviamo e otteniamo:

$$\frac{d}{d\lambda}\log f(x_1, x_2, \dots, x_n | \lambda) = \frac{1}{\lambda} \sum_{i=1}^{n} x_i - n$$

Da questo bro possiamo ottenere un'espressione per la stima  $\hat{\lambda}$ :

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

La stessa formula può essere applicata al campione  $X_1, X_2, \dots, X_n$ :

$$P{X_i = 1} = 1 - P{X_i = 0}$$

**Esempio** Numero di incidenti stradali in 10 giornate senza pioggia Dataset: { 4 0 6 5 2 1 2 0 4 3 }

Si vuole stimare per quell'anno la frazione di giornate senza pioggia con 2 incidenti o meno

$$\overline{X} = \frac{1}{10} \sum_{i=1}^{10} X_i = 2.7$$

Cosi otteniamo che la media della poissoniana è 2.7, la stima desiderata è data da:

$$(1+2.7+(2.7)^2/2)e^{-2.7} \approx 0.4936$$

### 2.3 MLE distribuzione Uniforme

$$f(X_1, \dots X_n | \theta) = \begin{cases} \frac{1}{\theta} & 0 < x_1 < \theta \\ 0 & \text{altrimenti} \end{cases}$$

La formula per la stima di heta

$$\hat{\theta} = \max\{X_1, \dots, X_n\}$$

### 2.4 MLE distribuzione Normale

TODO AGGIUNGERE THETA MAX THETA / 2

**Definizione:** La distribuzione normale ha media  $\mu$  e dev. st.  $\sigma$  incognite La densità congiunta (la likelihood) è data da:

$$f(x_1, x_2, \dots, x_n | \mu, \sigma) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\mu\sigma}} \exp\left\{-\frac{(x_1 - \mu)^2}{2\sigma^2}\right\}$$

La log-likelihood (metodo semplificato per migliorarci la vita che è già una merda) è data da:

$$\log f(x_1, x_2, \dots, x_n | \mu, \sigma) = -\frac{n}{2} \log(2\pi) - n \log \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^{n} (x_i - \mu)^2$$

La risoluzione (che lasciamo al libro) ci porta alle formule per le stime:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^{n} x_1$$

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (x_i - \hat{\mu})^2}$$

#### TODO TEORIA DEL LIMITE CENTRALE

## 3 Intervalli di confidenza

# 3.1 $\mu$ incognita e varianza $\sigma^2$ nota

Sia  $X_1, X_2, \ldots, X_n$  un campione di una popolazione normale con  $\mu$  incognita e varianza  $\sigma^2$  nota

$$\frac{\overline{X} - \mu}{\sigma / \sqrt{n}} \sim \mathcal{N}(0, 1)$$

Chiedo aiuto alla regia, non so cosa stia sta roba ma comunque:

$$P\left(\overline{X} - 1.96 \frac{\sigma}{\sqrt{n}} < \mu < \overline{X} + 1.96 \frac{\sigma}{\sqrt{n}} \approx 0.95\right)$$

Il 95% circa delle volte  $\mu$  starà a una distanza non superiore a 1.96  $\sigma/\sqrt{n}$  dalla media aritmetica dei dati. Se osserviamo il campione, e registriamo che  $\overline{X}=\overline{x}$ , allora possiamo dire che "con il 95% di confidenza"

$$\left(\overline{x} - 1.96 \frac{\sigma}{\sqrt{n}}, \overline{x} + 1.96 \frac{\sigma}{\sqrt{n}}\right)$$

Questo intervallo è detto intervallo di confidenza ad un livello del 95%

**Esempio** segnale elettrico di valore  $\mu$ 

i valori registrati sono i seguenti: 5 8.5 12 15 7 9 7.5 6.5 10.5

Otteniamo  $\overline{x}$ :

$$\overline{x} = \frac{81}{9} = 9$$

Un intervallo di confidenza al 95% per  $\mu$  è

$$\left(9 - 1.96\frac{2}{3}, \quad 9 + 1.96\frac{2}{3}\right) = (7.69, 10.31)$$

Otteniamo quindi il 95% di fiducia che il messaggio fosse compreso tra 7.69 e 10.31

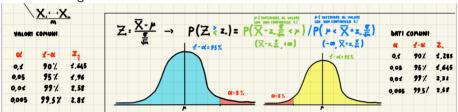


Figure 1: TODO CAPIRE CHE SFACCIMM è STA ROBA

# 3.2 $\mu$ incognita e varianza $\sigma^2$ incognita

Dato che tutti i nostri parametri sono ignoti, non possiamo basarci sul fatto che  $\sqrt{n}(\overline{X}-\mu)/\sigma$  è una *normale standard*, dobbiamo quindi ricorrere a una varianza campionaria come segue:

$$S^{2} := \frac{1}{n-1} \sum_{i} (X_{i} - \overline{X})^{2} \longrightarrow \frac{\overline{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}$$

Alla fine otteniamo una variabile aleatoria di tipo t con n-1 gradi di libertà

#### Per Bilaterale

$$P\left\{\overline{X} - t_{\frac{\alpha}{2}, n-1} \frac{S}{\sqrt{n}} < \mu < \overline{X} + t_{\frac{\alpha}{2}, n_1} \frac{S}{\sqrt{n}}\right\} = 1 - \alpha$$

#### Per Unilaterale

$$P\left(\overline{X} - t_{\frac{\alpha}{2}, n-1} \frac{\sigma}{\sqrt{n}} < \mu\right) / P\left(\mu < \overline{X} + t_{\frac{\alpha}{2}, n_1} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

### 3.3 Metodo Montecarlo

supponendo di avere una funzione f da  $\mathbb{R}^r$  in  $\mathbb{R}$  e vogliamo stimare la quantità  $\theta$ :

$$\theta := \int_0^1 \int_0^1 \cdots \int_0^1 f(y_1, y_2, \dots, y_n) \, dy_1 \, dy_2 \dots \, dy_n$$

Possiamo notare che  $U_1, U_2, \ldots, U_r$  sono var. al. *uniformi* su 0,1 quindi:

$$\mathbb{E}[f(U_1, U_2, \dots, U_r)] = \theta$$

Se produciamo un numero casuale distribuito come la funzione e lo ripetiamo n volte, possiamo stimare  $\pmb{\theta}$ 

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^{n} X_i$$

Esempio pensiamo alla stima di questo integrale:

$$\theta := \int_0^1 \sqrt{1 - y^2} \, dy = \mathbb{E}[\sqrt{1 - U^2}]$$

Se  $U_1, U_2, \ldots, U_{100}$  sono variabili aleatorie con tale distribuzione e indipendenti ponendo

$$X_i := \sqrt{1 - U_i^2}$$
  $i = 1, 2, \dots, 100$ 

Otteniamo un campione di **100** variabili aleatorie di media  $\theta$ . Calcoliamo ora la media campionaria:

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^{n} X_1 = 0.786$$

e successivamente la deviazione standard campionaria:

$$S = 0.23$$

dato che  $t_{0.025,99} \approx 1.985$  otteniamo che un intervallo di confidenza al 95% per  $\theta$  è il seguente:

$$0.786 \pm 1.985 \cdot 0.023$$

Quindi il valore è compreso tra 0.740 e 0.832

# 4 Intervalli di predizione

# 4.1 $\mu$ incognita e varianza $\sigma^2$ incognita

Supponiamo che  $X_1,X_2,\ldots,X_n,X_{n+1}$  sia un campione normale di media  $\mu$  e varianza  $\sigma^2$  entrambe incognite

$$\mu = \overline{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$$

### Per la riproducibilità

$$X_{n+1} - \overline{X}_n \sim \mathcal{N}(0, \sigma^2 + \frac{\sigma^2}{n}) \longrightarrow \frac{X_{n+1} - \overline{X}_n}{\sigma \sqrt{1 + 1/n}}$$

Dato che  $\sigma$  è incognita dobbiamo sostituirla col suo stimatore (scegliendo la *devi-azione standard campionaria* quindi poniamo:

$$S_n^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

Questa grandezza è indipendente da  $\overline{X}_n$  quindi otteniamo

$$\frac{X_{n+1} - \overline{X}_n}{S_n \sqrt{1 + 1/n}} \sim t_n - 1$$

**Esempio** prendiamo in campione i valori rilevati da un contapassi negli ultimi 7 giorni

Dataset: 6822 5333 7420 6252 7005 6752

Si trovi l'intervallo di predizione al 95% di confidenza

Risoluzione: le statistiche del campione sono:

$$\overline{X}_7 \approx 6716.57$$
  $S_7 \approx 733.97$ 

Dalle tabelle ricaviamo che  $t_{0.025,6}\approx 2.447$  (+ altri passaggi) concludiamo col dire che il 95% di confidenza che  $X_8$  cadrà nell'intervallo [4796, 8637]

# 4.2 Intervalli di confidenza per la varianza

Se  $X_1, X_2, \ldots, X_n$  è un campione di una distribuzione *normale* con parametri  $\mu$   $\sigma^2$  **incogniti** ci possiamo basare sul fatto che

Formula generica:

$$(n-1)\frac{S^2}{\sigma^2} \sim \mathcal{X}_{n-1}^2$$

Per caso Bilaterale

$$\left(\frac{(n-1)s^2}{\chi^2_{\frac{\alpha}{2},n-1}}, \frac{(n-1)s^2}{\chi^2_{1-\frac{\alpha}{2},n-1}}\right) \tag{1}$$

Per caso Unilaterale

$$P\left(0 < \sigma^2 < \frac{(n-1)S^2}{\mathcal{X}_{1-\alpha,n-1}^2}\right) / P\left(\frac{(n-1)S^2}{\mathcal{X}_{\alpha,n-1}^2} < \sigma^2\right)$$
 (2)

#### Stime per la differenza tra le medie di due popolazioni 4.3 normali

Siano  $X_1, X_2, \dots, X_n$  e  $Y_1, Y_2, \dots, Y_m$  due campioni normali e differenti e denotiamo con  $\mu_1$  e  $\sigma_1^2$  e con  $\mu_2$  e  $\sigma_2^2$   $\overline{X}-\overline{Y}$  è lo stimatore di massima verosomiglianza  $\mu_1-\mu_2$ 

**Tabella 7.1** Intervalli con livello di confidenza  $1 - \alpha$  per campioni normali.

$$\overline{X}_1, X_2, \dots, X_n \sim \mathcal{N}\left(\mu, \sigma^2\right)$$

$$\overline{X} := \frac{1}{n} \sum_{i=1}^n X_i, \qquad S := \left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \overline{X})^2\right)^{1/2}$$

Ipotesi	θ	Intervallo bilaterale	Intervallo sinistro	Intervallo destro
$\sigma^2$ nota	$\mu$	$\overline{X}\pm z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}$	$\left(-\infty, \overline{X} + z_{\alpha} \frac{\sigma}{\sqrt{n}}\right)$	$\left(\overline{X} - z_{\alpha} \frac{\sigma}{\sqrt{n}}, \infty\right)$
$\sigma^2$ non nota	$\mu$	$\overline{X}\pm t_{\frac{\alpha}{2},n-1}\frac{S}{\sqrt{n}}$	$\left(-\infty, \overline{X} + t_{\alpha, n-1} \frac{S}{\sqrt{n}}\right)$	$\left(\overline{X} - t_{\alpha, n-1} \frac{S}{\sqrt{n}}, \infty\right)$
$\mu$ non nota	$\sigma^2$	$\left(\frac{(n-1)S^2}{\chi^2_{\frac{\alpha}{2},n-1}},\frac{(n-1)S^2}{\chi^2_{1-\frac{\alpha}{2},n-1}}\right)$	$\left(0, \frac{(n-1)S^2}{\chi^2_{1-\alpha,n-1}}\right)$	$\left(\frac{(n-1)S^2}{\chi^2_{\alpha,n-1}},  \infty\right)$

Per ottenere uno  $\it stimatore$  non puntuale, dobbiamo conoscere la distribuzione di  $\overline{X}-\overline{Y}$  poiche:

$$\overline{X} \sim \mathcal{N}\left(\mu_1, \frac{\sigma_1^2}{n}\right) \qquad e \qquad \overline{Y} \sim \mathcal{N}\left(\mu_2, \frac{\sigma_2^2}{m}\right)$$

Possiamo dedurre che:

$$\overline{X} - \overline{Y} \sim \mathcal{N}\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right)$$

lpotizzando di conoscere  $\sigma_1^2$  e  $\sigma_2^2$  abbiamo che:

$$\frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2 / n + \sigma_2^2 / m}} \sim \mathcal{N}(0, 1)$$

e possiamo dedurre, con i passaggi che ci sono ormai familiari, che

#### Per caso Bilaterale

$$1 - \alpha = P\left(-z_{\frac{\alpha}{2}} < \frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n + \sigma_2^2/m}} < z_{\frac{\alpha}{2}}\right)$$

$$= P\left(\overline{X} - \overline{Y} - z_{\frac{\alpha}{2}}\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} < \mu_1 - \mu_2 < \overline{X} - \overline{Y} + z_{\frac{\alpha}{2}}\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}\right)$$

#### Per caso Unilaterale

$$1 - \alpha = P\left(\overline{X} - \overline{Y} - z_{\alpha}\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} < \mu_1 - \mu_2\right)/P$$
$$= \left(\mu_1 - \mu_2 < \overline{X} - \overline{Y} - z_{\alpha}\sqrt{\frac{\sigma_2^2}{n} + \frac{\sigma_2^2}{m}}\right)$$

## 5 Intervalli di confidenza

### 5.1 Intervalli approssimati per Bernoulli

Nel caso avessimo n oggetti con una quantita X di oggetti che soddisfano i requisiti, possiamo dire che X ha distribuzione  $\emph{binomiale}$  di parametri n e p

$$\frac{X - np}{\sqrt{np(1 - p)}} \sim \mathcal{N}(0, 1)$$

Per ottenere un intervallo per p denotiamo con  $\hat{p} := X/n$  la frazione degli oggetti del campione che soddisfano i requisiti, quindi:

$$\frac{X - np}{\sqrt{n\hat{p}(1 - \hat{p})}} \sim \mathcal{N}(0, 1)$$

Da questa formula possiamo ottenere cosi un intervallo di confidenza

#### Per caso Bilaterale

$$1-\alpha = P\left(\hat{p} - z_{\frac{\alpha}{2}}\sqrt{\hat{p}(1-\hat{p})/n}$$

#### Per caso Unilaterale

$$P\left(\hat{p} - z_{\frac{\alpha}{2}}\sqrt{\hat{p}(1-\hat{p})/n} < p\right)/P\left(p < \hat{p} + z_{\frac{\alpha}{2}}\sqrt{\hat{p}(1-\hat{p})/n}\right)$$

**Esempio** Un campione di 100 transitor viene testato. 80 pezzi sono adeguati Volendo trovare un intervallo del 95% per la percentuale p scriviamo:

$$\left(0.8 - 1.96\sqrt{0.8 \cdot 0.2/100}, \quad 0.8 + 1.96\sqrt{0.8 \cdot 0.2/100}\right) = (0.7216, \quad 0.8784)$$

Possiamo dire quindi con il 95% di confidenza che sarà *accettabile* una percentuale compresa tra il **72.16%** e il **87.84%** 

Tipo di intervallo	Intervallo di confidenza $\hat{p}\pm z_{rac{lpha}{2}}\sqrt{\hat{p}(1-\hat{p})/n}$	
Bilaterale		
Unilaterale sinistro	$\left(-\infty, \hat{p}+z_{lpha}\sqrt{\hat{p}(1-\hat{p})/n} ight)$	
Unilaterale destro	$\left(\hat{p} - z_{\alpha}\sqrt{\hat{p}(1-\hat{p})/n},  \infty\right)$	

# 5.2 Qualità ed efficienza degli stimatori

Sia  $X:=(X_1,X_2,\ldots,X_n)$  un campionare di una distribuzione *nota* tranne per il parametro  $\theta$  che è incognito e d(X) uno stimatore di  $\theta$  Come possiamo valutare la sua efficacia? un criterio può essere quello dell'*errore* 

$$r(d, \theta) := \mathbb{E}[(d(X) - \theta)^2]$$

e sarà questo il nostro indicatore del valore di d come stimatore di  $\theta$ 

#### 5.2.1 Bias e Polarizzazione

quadratico medio ossia:

**Definizione:** Sia d = d(X) uno stimatore del parametro  $\theta$  allora:

$$b_{\theta}(d) := \mathbb{E}[d(X)] - \theta$$

Questo viene detto bias di d come stimatore di  $\theta$ Se il bias è nullo, si dice che è uno stimatore corretto o non distorto **Esempio** Sia  $X_1, \ldots, X_n$  un campione con media *incognita*  $\theta$  quindi:

$$d_1(X_1, X_2, \dots, X_n) = X_1$$

$$d_2(X_1, X_2, ..., X_n) = \frac{X_1 + X_2 + \dots + X_n}{n}$$

sono entrambi stimatori non distorti di heta

verifichiamo:

$$\mathbb{E}[X_1] = \mathbb{E}\left[\frac{X_1 + X_2 + \dots + X_n}{n}\right] = \theta$$

Se d = d(X) è uno *stimatore corretto*, il suo errore quadratico medio è

$$r(d, \theta) = \mathbb{E}[(d - \theta)^2]$$
$$= \mathbb{E}[(d - \mathbb{E}[d])^2]$$
$$= Var(d)$$

Questo è lo stimatore migliore con Varianza minima

### Regola generale

$$d_3(X_1,X_2,\ldots,X_n):=\sum_{i=1}^n\lambda_iX_i$$
 è corretto se  $\sum_{i=1}^n\lambda_i=1$ 

#### 5.2.2 Combinazioni di stimatori corretti

Consideriamo due stimatori corretti e indipendenti di parametro  $\theta$  (denotati con  $d_1$  e  $d_2$ ) con varianze rispettivamente  $\sigma_1^2$   $\sigma_2^2$ 

$$\mathbb{E}[d_i] = \theta \quad Var(d_i) = \sigma_i^2 \qquad i = 1, 2$$

uno stimatore corretto di  $\theta$  è il seguente

$$d := \lambda d_1 + (1 - \lambda)d_2$$

Successivamente vogliamo trovare anche il valore di  $\lambda$  che produce lo stimatore d con il minore errore quadratico medio

$$\begin{split} r(d,\theta) &= Var(d) \\ &= \lambda^2 Var(d_1) + (1-\lambda)^2 Var(d_2) \qquad \text{per l'indipendenza di $d_1$ e $d_2$} \\ &= \lambda^2 \sigma_1^2 + (1-\lambda)^2 \sigma_2^2 \end{split}$$

ayo bro what's this shit, le me calculate the derivata with latti:

$$\frac{d}{d\lambda}r(d,\theta) = 2\lambda\sigma_1^2 - 2(1-\lambda)\sigma_2^2$$

e belin lo studiamo sto segno o no? denotiamo con  $\hat{\lambda}$  il valore di  $\theta$  che produce il minimo

$$2\hat{\lambda}\sigma_1^2 - 2(1-\hat{\lambda})\sigma_2^2 = 0$$

da cui otteniamo:

$$\hat{\lambda} = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2} = \frac{1/\sigma_1^2}{1/\sigma_1^2 + 1/\sigma_2^2}$$

il peso ottimale da dare a uno stimatore deve essere **inversamente** proporzionale alla sua varianza

La migliore combinazione lineare delle  $d_i$  per l'errore quadratico medio è:

$$\begin{split} r(d,\theta) &= Var(d) \\ &= \left(\frac{1}{\sum_{i=1}^n} 1/\sigma_i^2\right)^2 \sum_{i=1}^n \left(\frac{1}{\sigma_i^2} \sigma_i^2\right) \\ &= \frac{1}{\sum_{i=1}^n 1/\sigma_i^2} \end{split}$$

$$r(d, \theta) = Var(d)$$

## Bias/Polarizzazione Se d(X) è distorto:

$$r(d,\theta) = \mathbb{E}[(d-\theta)^2]$$
$$= Var(d) + 0 + \mathbb{E}[b_{\theta}(d)^2]$$
$$= Var(d) + b_{\theta}(d)^2$$



## 5.3 Stimatore della media di una distribuzione uniforme

Siano  $X_1, X_2, \ldots, X_n$  un campione estratto da una popolazione con distribuzione uniforme su  $(0,\theta)$  dove  $\theta$  è un parametro incognito.

Dato che (non si sa come)  $\mathbb{E}[X_i] = heta/2$  è uno stimatore naturale per heta è dato da

$$d_1 = d_1(X) := 2\overline{X} := \frac{2}{n} \sum_{i=1}^n X_i$$

Siccome  $\mathbb{E}[d_1] = \theta$ , otteniamo che:

$$r(d_1, \theta) = Var(d_1)$$

$$= \frac{4}{n} Var(X_i)$$

$$= \frac{4}{n} \cdot \frac{\theta^2}{12}$$

$$= \frac{\theta^2}{3n}$$

Un secondo stimatore che abbiamo è quello di massima verosomiglianza  $(d_2)$ :

$$d_2 = d_2(X) = MLE := \max(X_i)$$

Per trovare l'errore quadratico medio di  $d_2$  dobbiamo prima conoscere la sua  $\it media$  e la sua  $\it varianza$ 

$$\mathbb{E}[d_2] = \int_0^\theta x \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{n+1}\theta$$

$$\mathbb{E}[d_2^2] = \int_0^\theta x^2 \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{n+2}\theta^2$$

$$Var(d_2) = \mathbb{E}[d_2^2] - \mathbb{E}[d_2]^2 = \frac{n\theta^2}{(n+2)(n+1)^2}$$

Quindi ora calcoliamo la  $r(d_2, \theta)$ :

$$r(d_{2},\theta) = \operatorname{Var}(d_{2}) + (E[d_{2}] - \theta)^{2}$$

$$= \frac{n\theta^{2}}{(n+2)(n+1)^{2}} + \frac{\theta^{2}}{(n+1)^{2}}$$

$$= \frac{\theta^{2}}{(n+1)^{2}} \left[ \frac{n}{n+2} + 1 \right]$$

$$= \frac{2\theta^{2}}{(n+1)(n+2)}$$
(3)

Confrontando gli errori quadratici medi notiamo che  $d_2$  è **migliore** di  $d_1$  per  $\theta$ 

$$\frac{2\theta^2}{(n+1)(n+2)} \le \frac{\theta^2}{3n} \qquad d_2 \text{ migliore}$$

• SI DEPOLARIZZA d. 
$$\rightarrow$$
 d.:  $\frac{m+d}{m}$  d. CORRETTO  $\rightarrow$   $F(d, \theta)$ :  $\forall AR(d, \theta)$ :  $\frac{(m+d)!}{m!}$   $\forall AR(d, \theta)$ :  $\frac{\theta}{m!}$   $\frac{\theta}{m!$ 

# 6 Stimatori Bayesiani

**Definizione:** Quando il parametro incognito  $\theta$  possiamo considerarlo come una variabile aleatoria, questo approccio viene detto *bayesiano*.

Se abbiamo delle informazioni su quelli che possono essere assunti i valori da  $\theta$  ed esse assumono la forma di distribuzione di probabilità si dice che abbiamo **una** 

#### distribuzione a priori per $\theta$

Se i valori che osserviamo sono  $X_i = x_i$  i = 1, 2, ..., n la densità di probabilità condizionale di  $\theta$  è data da:

$$f(\theta|x_1, x_2, \dots, x_n) = \frac{f(x_1, x_2, \dots, x_n, \theta)}{f(x_1, x_2, \dots, x_n)}$$
$$= \frac{f(x_1, x_2, \dots, x_n|\theta)p(\theta)}{\int f(x_1, x_2, \dots, x_n|\theta')p(\theta')d\theta'}$$

Dove:

- $f(\theta|x_1,x_2,\ldots,x_n)$  Viene detta probabilità a posteriori
- $f(x_1, x_2, \ldots, x_n)$  è la MLE Marginale
- $f(x_1, x_2, \dots, x_n | \theta)$  è la MLE
- $p(\theta)$  è la distribuzione a priori

Una buona stima per  $\theta$  può essere la **media** perciò:

$$\mathbb{E}[\theta|X_1=x_1,\ldots,X_n=x_n]=\int_{-\infty}^{\infty} \theta f(\theta|x_1,x_2,\ldots,x_n)\,d\theta$$
 nel caso continuo

## 6.1 Stimatore di $\theta$ per Bernoulli

Se abbiamo  $X_1, X_2, \ldots, X_n$  Bernoulliane, con massa di probabilità:

$$f(x|\theta) = \theta^x (1-\theta)^{1-x} \qquad x = 0, 1$$

Dove  $\theta$  è un parametro sconosciuto

Supponiamo quindi che la distribuzioni a priori di  $\theta$  sia uniforme su (0,1), denotiamo con p la densità a propri di  $\theta$ 

$$p(\theta) = 1 \qquad 0 < \theta < 1$$

La densità condizionale di  $\theta$  date  $x_1, x_2, \ldots, x_n$  è

$$f(\theta \mid x_1, x_2, \dots, x_n) = \frac{f(x_1, x_2, \dots, x_n, \theta)}{f(x_1, x_2, \dots, x_n)}$$

$$= \frac{f(x_1, x_2, \dots, x_n \mid \theta) p(\theta)}{\int_0^1 f(x_1, x_2, \dots, x_n \mid \theta) p(\theta) d\theta}$$

$$= \frac{\theta^{\sum_i x_i} (1 - \theta)^{n - \sum_i x_i}}{\int_0^1 \theta^{\sum_i x_i} (1 - \theta)^{n - \sum_i x_i} d\theta}$$
(4)

Non è difficile provare (e invece lo è) integrando per parti un certo numero di volte che per ogni valore di m e r:

$$\int_0^1 \theta^m (1 - \theta)^r d\theta = \frac{m! r!}{(m + r + 1)!}$$

poniamo ora  $x := \sum_{i=1}^n x_i$ 

$$f(\theta|x_1, x_2, \dots, x_n) = \frac{(n+1)!}{x!(n-x)!} \theta^x (1-\theta)^{n-x} \qquad 0 < \theta < 1$$

Ora siamo in grado di calcolare la stima bayesiana

$$E\left[\theta \mid x_{1}, x_{2}, \dots, x_{n}\right] = \frac{(n+1)!}{x!(n-x)!} \int_{0}^{1} \theta^{1+x} (1-\theta)^{n-x} d\theta$$

$$= \frac{(n+1)!}{x!(n-x)!} \frac{(1+x)!(n-x)!}{(n+2)!}$$

$$= \frac{x+1}{n+2}$$

$$= \frac{1+\sum_{i=1}^{n} X_{i}}{n+2}$$
(5)

**Esempio** Se raccogliamo un campione di 10 bernoulliane e trovassimo 6 successi, lo stimatore bayesiano di  $\theta$  fornirebbe un valore di 7 / 12 Lo stimatore di massima verosomiglianza vale invece 6 / 10

## 6.2 Stimatore di $\theta$ per una Normale

Supponiamo che  $X_1, X_2, \ldots, X_n$  sia una distribuzione normale con media  $\theta$  incognita e varianza  $\sigma_0^2$  **nota** 

Calcoliamo la densità condizionale di  $\theta$ :

$$f(\theta|x_1, x_2, \dots, x_n) = \frac{f(x_1, x_2, \dots, x_n|\theta)p(\theta)}{f(x_1, x_2, \dots, x_n)}$$

Ora calcoliamo la media:

$$\mathbb{E}[\theta|X_1,X_2,\ldots,X_n] = \frac{n/\sigma_0^2}{n/\sigma_0^2 + 1/\sigma^2} \overline{X} + \frac{1/\sigma^2}{n/\sigma_0^2 + 1/\sigma^2} \mu$$

e successivamente la varianza

$$Var(\theta|X_1, X_2, \dots, X_n) = \frac{1}{n/\sigma_0^2 + 1/\sigma^2}$$

# 6.3 Stimatore di heta per Uniformi

Avendo una funzione di likelihood  $f(x_1,x_2,\ldots,x_n|\theta)$  e sapendo che la distribuzione è *uniforme* 

$$\theta \in [a, b]$$
$$d_b = d_{MLE}$$

# 7 Verifica delle ipotesi

Se prima noi cercavamo di stimare determinati parametri ora cerchiamo invece (avendo un campione raccolto) di trovare le ipotesi che li coinvolga

# 7.1 Livelli di significatività

Consideriamo una popolazione con distribuzione  $F_{\theta}$  che dipende da  $\theta$  incognito e vogliamo verificare una qualche ipotesi su  $\theta$ , una distribuzione normale con media  $\theta$  e varianza 1 abbiamo due ipotesi

- 1.  $H_0: \theta = 1 \rightarrow \textit{lpotesi nulla semplice}$
- 2.  $H_0: \theta \leq n \rightarrow lpotesi nulla composta$

La prima ipotesi afferma che la popolazione ha come distribuzione  $\mathcal{N}(\mathbf{1},\mathbf{1})$  mentre la seconda sostiene che è normale con *varianza* 1 e *media* **non** superiore a 1. Queste due ipotesi si possono verificare su un campiona aleatorio  $X_1,X_2,\ldots X_n$ 

Esiste una regione critica  ${\bf C}$  per cui se il campione aleatorio vi appartiene l'ipotesi non viene accettata. Esiste un livello di tolleranza specificato all'interno della regione critica per cui un'ipotesi può essere ancora accettata. Questa tolleranza è definita dal **livello di significatività**, ovvero viene definito  $\alpha$  tale che se l'ipotesi è vera la probabilità di rifiutarla non superi  $\alpha$ 

accetta 
$$H_0$$
 se $(X_1, X_2, \dots, X_n) \notin C$ 

e

rifiuta 
$$H_0$$
 se $(X_1, X_2, \dots, X_n) \in C$ 

Esistono due tipi di errori:

- 1. **Prima Specie**: Si rifiuta  $H_0$  anche se è vera
- 2. **Seconda Specie**: si accetta  $H_0$  anche se è falsa

# 7.2 Verifica di ipotesi sulla media di una popolazione normale

Supponiamo di avere  $X_1, X_2, \ldots, X_n$  sia un campione aleatorio di una popolazione normale di parametri  $\mu$   $\sigma^2$  con *varianza* nota e *media* incognita, vogliamo verificare le seguenti ipotesi:

$$H_0: \mu = \mu_0$$

e l'ipotesi alternativa

$$H_1: \mu \neq \mu_0$$

Lo stimatore puntuale per  $\mu$  è:

$$\overline{X} := \frac{1}{n} \sum_{i=1}^{n} X_i$$

La regione critica del test invece è:

$$C := \{(X_1, X_2, \dots, X_n) : |\overline{X} - \mu_0| > c\}$$

Dove c rappresenta la tolleranza

Quando  $\mu=\mu_0$  sappiamo che  $\overline{X}$  ha distribuzione **normale** con media  $\mu_0$  e varianza  $\sigma^2/n$  allora:

$$\frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}} \sim Z$$

Dove la relazione  $\sim$  è **condizionata** all'ipotesi  $H_0: \mu = \mu_0$ 

c deve soddisfare la seguente relazione:

$$lpha = P( ext{errore di I specie}) = P_{\mu_0}(|\overline{X} - \mu_0) > c$$

Possiamo scrivere l'equazione di sopra in questo modo:

$$\alpha = 2P\left(Z > \frac{c\sqrt{n}}{\sigma}\right)$$

Per  $P(Z>c\sqrt{n}/\sigma)$  per la definzione  $z_{\frac{\alpha}{2}}$  vale:

$$P\left(Z>z_{\frac{\alpha}{2}}\right)=\frac{\alpha}{2}\longrightarrow c=z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}$$

Il test con livello di significatività ha due esiti:

si rifiuta 
$$H_0$$
 se $\left|rac{\overline{X}-\mu_0}{\sigma/\sqrt{n}}
ight|>z_{rac{lpha}{2}}$ 

si accetta 
$$H_0$$
 se $\left| \frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}} \right| \leq z_{\frac{\alpha}{2}}$ 

p dei dati 
$$=\sqrt{n}rac{\overline{X}-\mu_0}{\sigma}$$

 $H_0$  si **accetta** se  $2P(Z>z_{\frac{\alpha}{2}})$  è elevata

 $H_0$  si **rifiuta** se  $2P(Z>z_{\frac{\alpha}{2}})$  è bassa

Perche se la probabilità che Z sia  $> z_{\frac{\alpha}{2}}$  è alta allora il mio valore sarà vicino al mezzo e va bene. Se è basso allora è lontano dal mezzo e non va bene.

**Esempio** supponiamo una media campionaria dei 5 segnali ricevuti fosse 8.5:

$$\frac{\sqrt{n}}{\sigma}|\overline{X} - \mu_0| = \frac{\sqrt{5}}{2} \cdot 0.5 \approx 0.559$$

Dato che:

$$P(|Z| > 0.559) = 2P(Z > 0.559) \approx 2X0.288 = 0.576$$

Otteniamo che il p-dei-dati è 0.576 e quindi l'ipotesi nulla che il segnale inviato fosse  ${\bf 8}$ , che viene accettata per ogni  $\alpha < 0.576$ 

Se avessimo ottenuto che  $\overline{X} = 11.5$  il valore del *p-dei-dati* sarebbe:

$$P\left(|Z| > \frac{\sqrt{5}}{2} \cdot 3.5\right) \approx 2P(Z > 3.913) \approx 0.00005$$

Con un valore così piccolo, l'ipotesi che il messaggio fosse stato 8, va rifiutata.

Riprendendo il discorso degli errori di specie andiamo a vedere ora *gli errori di* seconda specie.

Rinfreschiamo la memoria, l'errore di seconda specie è quando si accetta  $H_0$  anche se è falsa, quindi:

$$eta(\mu) := P_{\mu}( ext{accettare } H_0) = P_{\mu}\left(-z_{rac{lpha}{2}} \leq rac{\overline{X} - \mu_0}{\sigma/\sqrt{n}} \leq z_{rac{lpha}{2}}
ight)$$

La funzione  $\beta(\mu)$  è detta **curva OC** (*curva operativa caratteristica*) e rappresenta la probabilità di accettare  $H_0$  quando la media reale è  $\mu$ .

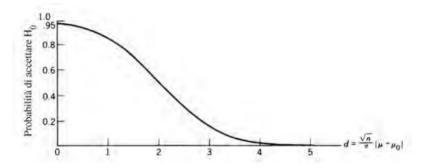


Figure 2: Curva OC di un test  $\it bilaterale$  per la media di una popolazione normale, con  $\alpha=0.05$ 

Per calcolare la probabilità ricordiamoci il fatto che  $\overline{X} \sim \mathcal{N}(\mu, \sigma^2/n)$ :

$$Z := \frac{\overline{X} - \mu}{\sigma / \sqrt{n}} \sim \mathcal{N}(0, 1)$$

Quindi:

$$\begin{split} \beta(\mu) &= P_{\mu} \left( -z_{\frac{\alpha}{2}} \leq \frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}} \leq z_{\frac{\alpha}{2}} \right) \\ &= \Phi \left( \frac{\mu_0 - \mu}{\sigma / \sqrt{n}} + z_{\frac{\alpha}{2}} \right) - \Phi \left( \frac{\mu_0 - \mu}{\sigma / \sqrt{n}} - z_{\frac{\alpha}{2}} \right) = 1 - \alpha \end{split}$$

Dove  $\Phi$  indica la funzione di ripartizione della distribuzione normale standard

**Esempio** quanto vale la probabilità di accettare  $\mu=8$  quando in realtà  $\mu=10$ :

$$\frac{\sqrt{n}}{\sigma}(\mu_0 - \mu) = \frac{\sqrt{5}}{2}(-2) = -\sqrt{5}$$

Dato che  $z_{0.025} pprox 1.96$  ricaviamo la probabilità cercata:

$$\beta(10) \approx \Phi(-\sqrt{5} + 1.96) - \Phi(-\sqrt{5} - 1.96)$$
$$= 1 - \Phi(0.276) - 1 + \Phi(4.196)$$
$$\approx -0.609 + 1 = \mathbf{0.391}$$

Riprendendo il discorso della curva OC, ci permette di dimensionare il campione in modo che *l'errore di seconda specie* soddisfi le condizioni specifiche.

Come facciamo a trovare n tale che la probabilità di accettare  $H_0: \mu = \mu_0$  quando il vero valore è  $\mu_1$  sia un valore fissato  $\beta$  per n tale che  $\beta(\mu_1) \approx \beta$ 

$$n \approx \left[ \frac{(z_{\frac{\alpha}{2}} + z_{\beta})\sigma}{\mu_1 - \mu_0} \right]^2$$

Notiamo che anche nel caso in cui  $\mu_1 < \mu_0$  troviamo sempre la stessa formula

**Esempio** Quante volte è necessario inviare il segnale con verifica dell'ipotesi  $H_0$ :  $\mu=8$  con livello di significatività 0.05 con almeno il 75% di probabilità di rifiutare l'ipotesi nulla quando  $\mu=9.2$ 

Dato che  $z_{0.025\approx 1.96}$  e  $z_{0.25}\approx 0.67$ 

$$n \approx \left(\frac{1.96 + 0.67}{1.2}\right)^2 \cdot 4 \approx 19.21$$

Come vediamo per il risultato è necessario un campione di 20 segnali, quindi con  $n=20\,$ 

$$\beta(9.2) \approx \Phi\left(-\frac{1.2\sqrt{20}}{2} + 1.96\right) - \Phi\left(-\frac{1.2\sqrt{20}}{2} - 1.96\right)$$
$$\approx \Phi(-0.723) - \Phi(-4.643)$$
$$\approx 1 - \Phi(0.723) \approx \mathbf{0.235}$$

Quindi ricapitolando, se il segnale viene trasmesso 20 volte c'è il 76.5% di probabilità che l'ipotesi nulla  $\mu=8$  sia **rifiutata** se la media reale è **9.2** 

#### 7.3 Test unilaterali

Introduzione bla bla bla Verifichiamo due ipotesi:

$$H_0: \mu = \mu_0$$
 contro  $H_1: \mu > \mu_0$ 

Dovremmo rifiutare l'ipotesi nulla quando lo stimatore di  $\mu$  è molto più grande di  $\mu_0$ , la regione critica è quindi:

$$C := \{(X_1, X_2, \dots, X_n) : \overline{X} - \mu_0 > c\}$$

la probabilità di rifiuto dovrebbe essere  $\alpha$  quando  $H_0$  è vera, occorre però che c soddisfi la relazione:

$$P_{\mu_0}(\overline{X} - \mu_0 > c) = \alpha$$

ll test *con livello di significatività* lpha dovrà rifiutare  $H_0$  se  $\overline{X} - \mu_0 > z_lpha \cdot \sigma / \sqrt{n}$ 

si rifiuta 
$$H_0$$
 se $\dfrac{\overline{X}-\mu_0}{\sigma/\sqrt{n}}>z_{lpha}$ 

si accetta 
$$H_0$$
 se $\dfrac{\overline{X}-\mu_0}{\sigma/\sqrt{n}} \leq z_{lpha}$ 

Quella trovata è detta *regione criticia* **unilaterale** o a una coda, quindi il problema di verificare le ipotesi alternative

$$H_0: \mu = \mu_0$$

$$H_1: \mu > \mu_0$$

Si dice problema di test unilaterale

poniamo  $Z:=\sqrt{n}(\overline{X}-\mu)/\sigma$  questa statistica è una *normale standard* quindi:

$$eta(\mu) := P_{\mu}( ext{accettare } H_0)$$
 
$$= P_{\mu}\left(Z \leq rac{\mu_0 - \mu}{\sigma/\sqrt{n}} + z_{lpha}
ight)$$
 
$$= \Phi\left(rac{\mu_0 - \mu}{\sigma/\sqrt{n}} + z_{lpha}
ight) = 1 - lpha$$

Dato che  $\Phi$  in quanto funzione di ripartizione è crescente però  $\beta(\mu)$  è una funzione decrescente

L'ipotesi unilaterale

$$H_0: \mu \leq \mu_0$$

contro l'alternativa

$$H_1: \mu > \mu_0$$

Per accertarci che il *livello di significatività* sia rimasto  $\alpha$ Al variare di  $\mu$  la probabilità di rifiuto è data da  $\mathbf{1} - \beta(\mu)$ Dobbiamo verificare che per ogni  $\mu$  compatibile con  $H_0$  per ogni  $\mu \leq \mu_0$ 

$$1 - \beta(\mu) \le \alpha$$
, per ogni  $\mu \le \mu_0$ 

Quindi:

$$\beta(\mu) \ge 1 - \alpha$$
, per ogni  $\mu \le \mu_0$ 

Osservazione è possibile verificare l'ipotesi

$$H_0: \mu = \mu_0$$

contro l'ipotesi alternativa

$$H_1: \mu < \mu_0$$

ad un livello di significatività lpha, decidendo che:

si rifiuta 
$$H_0$$
 se  $\dfrac{\overline{X}-\mu_0}{\sigma/\sqrt{n}} \leq -z_{lpha}$ 

si accetta 
$$H_0$$
 se  $\dfrac{\overline{X}-\mu_0}{\sigma/\sqrt{n}} \geq -z_{lpha}$ 

### 7.4 Il test t

Fino ad ora abbiamo supposto che l'unico parametro incognito fosse la media, in questo caso la nostra varianza  $\sigma^2$  non è nota

In questa situazione consideriamo che si possa verificare l'ipotesi nulla che  $\mu$  sia uguale ad un valore assegnato  $\mu_0$  contro l'ipotesi alternativa  $\mu \neq \mu_0$ 

$$H_0: \mu = \mu_0$$

$$H_1: \mu \neq \mu_0$$

(Cambiare poi con desc più corta) Come in precedenza, sembra ragionevole rifiutare l'ipotesi nulla quando  $\overline{X}$  cade lontano da  $\mu_0$  tuttavia la distanza a cui deve essere da  $\mu_0$  per giustificare questo rifiuto, dipende dalla deviazione standard  $\sigma$  che in quella sede era nota; in particolare  $|\overline{X}-\mu_0|$  doveva essere maggiore di  $z_{\frac{\alpha}{2}}\cdot\sigma/\sqrt{n}$  o equivalentamente

$$\left\lceil \frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}} \right\rceil > z_{\frac{\alpha}{2}}$$

Qui  $\sigma$  non è più conosciuta, sostituiamola quindi con la deviazione standard campionaria S

$$S := \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2}$$

rifiutando l'ipotesi nulla quando

$$\left| \frac{\overline{X} - \mu_0}{S/\sqrt{n}} \right|$$

Quindi alla fine noi dobbiamo ottenere una distribuzione t

$$t_{n-1} \sim \frac{\overline{X} - \mu}{S/\sqrt{n}}$$

Se si denota con T la statistica di questo test, ovvero

$$T := \frac{\overline{X} - \mu_0}{S/\sqrt{n}}$$

allora quando  $H_0$  è vera (visto che  $\mu=\mu_0$ ) ha distribuzione t con n-1 gradi di libertà.

$$P_{\mu_0}\left(-c \le \frac{\overline{X} - \mu_0}{S/\sqrt{n}} \le c\right) = \mathbf{1} - \boldsymbol{\alpha}$$

Se vogliamo ricavare c:

$$\alpha = 1 - P(-c \le T < c)$$

$$= P(T \le -c) + P(T \ge c)$$

$$= 2P(T \ge c)$$

Per cui  $P(T>c)=rac{lpha}{2}$ , e quindi deve valere  $c=t_{rac{lpha}{2},n-1}$ , quindi in fin dei conti:

si rifiuta 
$$H_0$$
 se  $\big|rac{\overline{X}-\mu_0}{S/\sqrt{n}}ig|>t_{rac{lpha}{2},n-1}$ 

si accetta 
$$H_0$$
 se  $\big| rac{\overline{X} - \mu_0}{S/\sqrt{n}} \big| \leq t_{rac{lpha}{2},n-1}$ 

Vedere tabella sotto per tutt'e cose

Figure 3:  $X_1, X_2, \ldots, X_n$  è un campionare estratto da una popolazione  $\mathcal{N}(\mu, \sigma^2)$ 

$$\sigma^2$$
 nota  $\overline{X} := \frac{1}{n} \sum_{1=1}^n X_i$ 

$H_0$	$H_1$	Statistica del test, $X_{ts}$	Si rifiuta $H_0$ con livello di significatività $\alpha$ se	$p$ -dei-dati se $X_{ m ts}=t$
$\mu = \mu_0$	$\mu \neq \mu_0$	$\frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}}$	$\ldots  X_{ts}  > z_{rac{lpha}{2}}$	2P(Z> t )
$\mu \le \mu_0$	$\mu > \mu_0$	$\frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}}$	$\dots X_{ts} > z_{lpha}$	P(Z > t)
$\mu \ge \mu_0$	$\mu < \mu_0$	$\frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}}$	$\dots X_{ts} < -z_{lpha}$	P(Z < t)

**Esempio** Vogliamo verificare l'ipotesi che il consumo *medio* di acqua sia *350* galloni al giorno.

Si misurano i consumi medi di un campione di 20 campioni che seguono:

340	356	332	362	318	344	386	402	322	360
362	354	340	372	338	375	364	355	324	370

Dobbiamo verificare le due ipotesi seguenti:

$$H_0: \mu=350$$
 contro  $H_1: \mu \neq 350$ 

#### Calcoliamo ora la media e la deviazione standard campionaria

$$\overline{X} = 353.8$$
  $S \approx 21.85$ 

troviamo ora il valore della statistica del test:

$$T \approx \frac{\sqrt{20} \cdot 3.8}{21.85} \approx 0.778$$

il valore che abbiamo trovato è minore di  $t_{0.05,19}\approx 1.729$  l'ipotesi nulla è accettata ad un livello del 5% TODO FINIRE PAGINA PDF 324 / 342 TOTALE

Figure 4:  $X_1,X_2,\ldots,X_n$  è un campionare estratto da una popolazione  $\mathcal{N}(\mu,\sigma^2)$  e  $\sigma^2$  non è nota

$$\overline{X} := \frac{1}{n} \sum_{i=1}^{n} X_i$$
  $S^2 := \frac{1}{n-1} \sum_{i=1}^{n} (\overline{X} - X_i)^2$ 

$H_0$	$H_1$	Statistica del test, $X_{ts}$	Si rifiuta $H_0$ con livello di significatività $\alpha$ se	$p$ -dei-dati se $X_{ts}=t$
$\mu = \mu_0$	$\mu \neq \mu_0$	$\frac{\overline{X} - \mu_0}{S/\sqrt{n}}$	$\dots  X_{ts}  > t_{\frac{\alpha}{2},n-1}$	$2P(T_{n-1} >  t )$
$\mu \le \mu_0$	$\mu > \mu_0$	$\frac{\overline{X} - \mu_0}{S/\sqrt{n}}$	$\dots X_{ts} > t_{\alpha,n-1}$	$P(T_{n-1} > t)$
$\mu \ge \mu_0$	$\mu < \mu_0$	$\frac{\overline{X} - \mu_0}{S/\sqrt{n}}$	$\dots X_{ts} < -t_{\alpha,n-1}$	$P(T_{n-1} < t)$

Nota:  $T_{n-1}$  ha distribuzione t con n-1 gradi di libertà. Inoltre  $P(T_{n-1} > t_{\alpha,n-1}) = \alpha$ .

## Verifica se due popolazioni hanno la stessa media

Esercizio 1 Probabilità che Oneto dia 30L (Lode)

$$\begin{array}{l} n = 120 \\ \sum_{i}^{120} x_{i} = 18 \\ \hat{P} = \frac{18}{120} = 0.15 \rightarrow 15\% \end{array}$$

Esercizio 2 N studenti da 30 e lode

$$n_1 = 18 \leftarrow \mathsf{Oneto}$$

$$n_2 = 20 \leftarrow \mathsf{Anguita}$$

 $n_{1,2} = 10 \leftarrow 30 \text{L}$  sia con Oneto che con Anguita

$$N=?$$
 Studenti da **30 e Lode** 
$$\hat{P_1} \approx \frac{n_1 2}{n_2} \qquad \qquad \hat{P_1} \approx \frac{n_1}{N} \qquad \qquad \frac{n_{1,2}}{n_2} = \frac{n_1}{N} \\ \Longrightarrow N = \frac{n_1 n_2}{n_1 n_2} \rightarrow \frac{18 \cdot 20}{10} = 36$$

**Esercizio 3** Stima del numero di incidenti medio in auto n = 10

$$x_1 = \{4, 0, 6, 5, 2, 1, 2, 0, 4, 3\}$$
  
 $\hat{\lambda} = \frac{\sum_i x_i}{n} = \frac{27}{10} = 2.7$ 

$$P\{x \le 2\} = e^{-2.7} \left(\frac{2.7^0}{0!} + \frac{2.7^1}{1!} + \frac{2.7^2}{2!}\right) \approx .4936 \to 49.36\%$$

Probabilità che non ci siano più di 2 incidenti

#### Esercizio gaussiana primo

$$x_1 = 1.7$$

$$x_2 = 1.82$$

$$x_3 = 1.73$$

$$x_4 = 1.7$$
  
 $x_5 = 1.8$ 

$$\hat{\mu} = \frac{\sum_{i} x_{i}}{n} = \frac{1.7 + 1.82 + 1.73 + 1.7 + 1.8}{5} = 1.75$$

$$\hat{\sigma} = \sqrt{\frac{0.05^{2} + 0.07^{2} + 0.02^{2} + 0.05^{2} + 0.05^{2}}{5}} \approx 0.051$$

**Esempio:** Sistema di comunicazione  $\sigma^2 = 4$  n = 9

$$x_1 = \{5.85, 12, 15, 7, 9, 7.5, 6, 5, 10.5\}$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^{n} x_i = \frac{1}{9} \sum_{i=1}^{n} x_i = \frac{81}{9} = 9$$

$$\begin{split} P\left(9-1.96\frac{\sigma}{\sqrt{m}} < \mu < 9+1.96\frac{\sigma}{\sqrt{m}}\right) &= 0.95 \\ p\left(9-1.96\frac{2}{3} < \mu < 9+1.96\frac{2}{3}\right) &= 0.95 \\ \longrightarrow [7.693, 10.31] \to \mu \text{ si trova tra } 7.693 \text{ e } 10.31 \end{split}$$

In generale Prob =  $1 - \alpha$ 

$$(\overline{x}-z_a\frac{\sigma}{\sqrt{n}},\overline{x}+z_a\frac{\sigma}{\sqrt{n}}) \to \mathsf{Si}$$
 rileva dalle tavole

### 7.6 Intervalli di confidenza (Unilaterali)

### 7.7 Esempio:

Pesca stagionale dei salmoni (Fisso intervallo -> trovo n) Ad ogni stagione il peso medio dei salmoni è diverso ma  $\sigma=0.3$  Kg Intervallo di confidenza al 95%, quindi  $\alpha=0.05$ 

$$(\overline{X}-1.96\frac{\sigma}{\sqrt{n}},\overline{X}+1.96\frac{\sigma}{\sqrt{n}})$$
 
$$1.96\frac{\sigma}{\sqrt{n}}\geq 0.1 \quad \sqrt{n}\geq \frac{1.96}{0.1}\sigma$$
 
$$n\geq (\frac{1.96}{0.1}0.3)^2=5.88^2\approx 34.6\leftarrow \mathsf{salmoni}$$

### 7.8 Intervallo di confidenza

con media e varianza incognite

**Esempio:** Trasimttente  $(\mu)$  e ricevitore  $(\mu + \text{rumore})$ 

$$95\%(7.69, 10.31)$$
  $\hat{\mu} = 9, \sigma^2 = 4$ 

$$X_i \{5, 8.5, 12, 15, 7, 9, 7.5, 6.5, 10.5\}$$

$$\hat{\mu} = \overline{X} = \frac{1}{9} \sum_{i}^{n} X_i = \frac{81}{9} = 9$$

$$s^2 = \frac{1}{8} \sum_{i} (X_i^2 - 9.81) \approx 9.5 \quad s = 3.082$$

$$\mu \in (9 - 2.306 \frac{3.082}{3}, 9 + 2.306 \frac{3.082}{3}) = (6.63, 11.37)$$

Si può dimostrare che  $T_{rac{lpha}{2}\cdot n-1}\mathbb{E}[S]\geq z_{lpha}\sigma$ 

#### 7.9 Intervallo di confidenza nella varianza

**Esempio:** Laminatoio n = 4  $X_i = \{0.123, 0.124, 0.126, 0.12\}$  spessore in mm

**Svolgimento** 

$$\frac{1}{4} \sum_{i=1}^{4} X_{i} = \frac{0.493}{4} = 0.12325$$

$$\frac{1}{4-1} \sum_{i=1}^{4} (X_{i} - 0.12325)^{2} = 1.875 \cdot 10^{-5}$$

$$\sigma^{2} \in \left(\frac{s^{2}(n-1)}{9.348}, \frac{s^{2}(n-1)}{0.216}\right)$$

Dove 9.348 e 0.216 sono ricavati dalle tabelle

Facciamo la radice:

 $\sigma \in (0.0014, 0.0093) \rightarrow 95\%$ 

### 7.10 Intervallo di confidenza

della differenza di due medie:

$$\begin{aligned} \textbf{N} \text{ campioni} & \textbf{M} \text{ campioni} \\ X_i &\sim \mathcal{N}(\mu_1, \sigma_1^2) & Y_i &\sim \mathcal{N}(\mu_2, \sigma_2^2) \\ \overline{X} &= \frac{1}{n} \sum_i^n X_i & \overline{Y} &= \frac{1}{m} \sum_i^m Y_i \\ \overline{X} &- \overline{Y} &\sim \mathcal{N} \left( \mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m} \right) \end{aligned}$$

$$\begin{split} \mathcal{N}(0,1) \sim \frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \\ \mu_1 - \mu_2 \in \left(\overline{X} - \overline{Y} - z_{\frac{\alpha}{2}}\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}, \overline{X} - \overline{Y} + z_{\frac{\alpha}{2}}, \overline{X} - \overline{Y} + z_{\frac{\alpha}{2}}\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}\right) \end{split}$$

Se  $\sigma_1^2, \sigma_2^2$  non sono note:

$$S_1^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})$$

$$S_2^2 = \frac{1}{m-1} \sum_{i=1}^{m} (X_i - \overline{Y})$$

$$(n-1) \frac{S_1^2}{\sigma_1^2} \sim \mathcal{X}_{n-1}^2$$

$$(n-1) \frac{s_2^2}{\sigma_2^2} \sim \mathcal{X}_{n-1}^2$$

Possiamo andare avanti solo se  $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 

$$(n-1)\frac{s_1^2}{\sigma^2} + (n-1)\frac{s_2^2}{\sigma^2} \sim \mathcal{X}_{n+m-2}^2$$

$$\frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{\sqrt{\sigma^2(\frac{1}{n} + \frac{1}{m})}} \longrightarrow \frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{\sqrt{S_p(\frac{1}{n} + \frac{1}{m})}}$$

$$\sim \mathcal{N}(0,1) \qquad \sim T_{n+m-2}$$

$$S_p = \frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}$$

Se  $\sigma$  sono ignote ma uguali

$$\mu_1 - \mu_2 \in (\overline{X} - \overline{Y} - T_{\frac{\alpha}{2}, n+m-2} \sqrt{s^2(\frac{1}{n} + \frac{1}{m})})$$

$$\overline{X} - \overline{Y} + T_{\frac{\alpha}{2}, n+m-2} \sqrt{s^2(\frac{1}{n} + \frac{1}{m})}$$

### 7.11 Intervallo di previsione

**Esempio** smartwatch contapassi n=7

$$LUN \quad 6922 \quad X_1 \qquad GIO \quad 7432 \quad X_4 \\ MAR \quad 5333 \quad X_2 \qquad VEN \quad 6252 \quad X_5 \\ MER \quad 7420 \quad X_3 \qquad SAB \quad 7005 \quad X_6$$

$$DOM \quad 6752 \quad X_7$$

$$\overline{X}_n = \frac{1}{n} \sum_{i}^{m} X_i = \frac{47016}{7} \approx 6717$$

$$1 - \alpha = 95\% \quad \alpha = 5\%$$

$$t_{0.0025,6} = 2.997$$

$$S_n = \sqrt{S_n^2} = 7.333.8$$

$$x_{n+1} \in (6717 - 2.447 \cdot 733397 \sqrt{1 + \frac{1}{7}}, 6717 + 2.447 \cdot 73397 \sqrt{1 + \frac{1}{7}})$$

$$X_{n+1} \in (9796, 8637) \mu \in (6037, 7396)$$

### 7.12 Qualità di uno stimatore

$$X = X_1 \dots X_n \quad \theta \leftarrow \text{parametro} \qquad d(x) \leftarrow \text{stimatore di } \theta$$
 
$$(d(x) - \theta)^2 \qquad \qquad \mathbb{E}[(d(x) - \theta)^2]$$

Errore Quadratico (*misura della qualità*) Errore Quadratico Medio (*M.S.E*) Rischio  $r(d,\theta)=\mathbb{E}[(d-\theta)^2]$  Lo stimatore "ottimo" sarà quello con il rischio minimo -> d con r minimo  $\theta$ 

**Esempio**  $d^*(x)=4$  se $\theta=4\Rightarrow d^*=$  stimatore ottimo(per tutti gli altri valori non va

### 7.13 Proprietà di uno stimatore

Def:  $b_{\theta}(d)=\mathbb{E}[d]- heta$  bias o polarizzazione Uno stimatore non è **polarizzato** se  $b_{\theta}(d)=0$ 

$$\begin{array}{ll} \textbf{Esempio} &: X_1 \dots X_n \quad \theta \text{media} \\ d_1(X_1 \dots X_n) &= X_1 \\ d_2(X_1 \dots X_n) &= \frac{X_1 + X_2}{2} \\ d_3(X_1 \dots X_n) &= \frac{X_1 + X_2 + \dots X_n}{n} \end{array}$$

Tutti questi sono unbiased

### 7.14 Stimatore unbaieseo

$$r(d,\theta)=\mathbb{E}[(d(x)-\theta)^2]=\mathbb{E}[(d(x)-\mathbb{E}[d(x)])^2]=Var(d)$$
tra gli stimatori non polarizzati di ottimo è quello con la varianza minima

#### 7.15 Valutazione di uno stimatore

$$X = X_1 \dots X_n \quad \theta = ?$$

Dove  $\theta$  è un parametro e d(x) è uno stimatore di  $\theta$ 

$$\begin{split} r(d,\theta) &(\text{mse}) \text{ rischio} \qquad b_{\theta}(d) = \mathbb{E}[d] - \theta \\ &\text{se } b_{\theta}(d) = 0 \Rightarrow r(d,\theta) = Var(d) \\ &\text{se } b_{\theta}(d) \neq 0 ? \ r(d,\theta) = ? \\ \\ r(d,\theta) &= \mathbb{E}[(d(x)-\theta)^2] = \mathbb{E}[(d(x)-\mathbb{E}[d]+\mathbb{E}[d]-\theta)^2] \\ &= \mathbb{E}[(d-\mathbb{E}[d])^2 + (\mathbb{E}[d]-\theta)^2 - 2(d-\mathbb{E}[d])(\mathbb{E}[d]-\theta)] \\ &= \mathbb{E}[(d-\mathbb{E}[d])^2] + \mathbb{E}[(\mathbb{E}[d]-\theta)^2] - 2(\mathbb{E}[d]-\theta) \cdot \mathbb{E}[(d-\mathbb{E}[d])] \\ \\ r(d,\theta) &= \mathbb{E}[(d-\mathbb{E}[d])^2] + \mathbb{E}[(\mathbb{E}[d]-\theta)^2] \\ &= Var(d) + b_{\theta}(d)^2 \leftarrow \mathsf{bias}^2 \end{split}$$

### 7 16 Esempio:

Stimatore della media di una distribuzione uniforme

$$\mathbb{E}[X_i] = \theta/2 \qquad d_1 = 2\frac{1}{n}\sum_i^n X_i X_1, X_2 \dots X_n \qquad d_2 = \max X_i$$

$$\begin{array}{l} d_1:\mathbb{E}[d_1]=\frac{2}{n}\sum_i\mathbb{E}[X_i]=\frac{2}{n}n\frac{\theta}{2}=\theta\\ r(d_1,\theta)=Var(d_1)=\frac{4}{n^2}nVar(X_i)=\frac{4}{n}\frac{\theta^2}{12}=\frac{\theta^2}{3n} \Leftarrow \textit{ Unbiased} \end{array}$$

$$F_2(x) = P_r\{d_2(x) \le x\} = P_r\{\max X_1 \le x\}$$

$$= P_r\{X_1 \le \forall i \in 1\} = \prod_{i=1}^n P_r\{X_i \le x\} = (\frac{x}{\theta})^n$$

$$f_2(x) = \frac{d}{dx}F_2(x) = n\frac{x^{n-1}}{\theta^n} \quad x \le \theta$$

$$\mathbb{E}[d_2] = \int_0^\theta x f_x(x) \, dx = \int_0^\theta \frac{n}{\theta^n} x^n \, dx = \frac{n}{\theta^n} \left[ \frac{x^{n+1}}{n+1} \Big|_0^\theta \right] = \frac{n}{n+1} \theta$$

$$\mathbb{E}[d_2^2] = \frac{n}{\theta^n} \int_0^\theta x^2 f(x) \, dx = \frac{n}{\theta^n} \int_0^\theta x^{n+1} \, dx = \frac{n}{\theta^n} \left[ \frac{x^{n+2}}{n+2} \Big|_0^\theta \right] = \frac{n}{n+2} \theta^2$$

$$Var(d_2) = \mathbb{E}[d^2] - \mathbb{E}[d_2]^2 = \frac{n}{n+2} \theta^2 - \frac{n^2}{(n+1)^2} \theta^2 = \frac{n}{(n+2)(n+1)^2} \theta^2$$

$$r(d_2, \theta) = Var(d_2) + (\mathbb{E}[d_2] - \theta)^2 = \frac{2 \cdot \theta^2}{(n+1)(n+2)}$$

$$n \ge 4$$
  $r(d_2, \theta) < r(d_1, \theta)$   $d_3 = \frac{n+1}{n}d_2$ 

In sintesi

$$r(d_1,\theta) = \frac{\theta^2}{3n} \Leftarrow \mathsf{Unbiased}$$
 
$$r(d_2,\theta) = \frac{2\theta^2}{(n+1)(n+2)} \Leftarrow \mathsf{Biased}$$
 
$$r(d_3,\theta) = \frac{\theta^2}{n^2+2n} \Leftarrow \mathsf{Unbiased}$$
 
$$r(d_4,\theta) = \frac{\theta^2}{(n+1)^2} \Leftarrow \mathsf{Biased}$$

# 8 Test di ipotesi

**lpotesi:** Affermazione rispetto a uno o più parametri di una distribuzione lpotesi da confutare:  $H_0$  (ipotesi nulla)

Esempio

$$X_1 \dots X_n \sim \mathcal{N}(\mu, \sigma^2)$$

$$H_0 : \mu = 0$$

$$H_a : \mu \neq 0$$
(6)

Diamo per scontato che l'ipotesi sia **vera** Dobbiamo cercare di *confutarla* 

### **Definizione** Regione critica tale che:

$$(X_1 \dots X_n) \in C \to H_0$$
è rifiutata  $(X_1 \dots X_n) \notin C \to H_0$ è accettata  $\alpha = \text{Livello di } \mathbf{significativit}$ à del test  $(\alpha = 10\%, 5\% \dots)$ 

#### Procedimento

- Fisso alpha
- ullet Suppongo che lpha sia vera
- ullet calcolo stima di  $\mu$
- verifico che non sia "troppo distante"

$$X_1 \dots X_n \sim \mathcal{N}(\mu, \sigma^2)$$
  

$$H_0 : \mu = \mu_0 \quad H_a : \mu \neq \mu_0$$
  

$$\overline{X} = \frac{1}{n} \sum_i X_i$$

$$\begin{array}{ll} \textbf{Regione critica} & \{(X_1 \dots X_n): |\overline{X} - \mu_0| > c\} \\ P_{r_{\mu_0}} \left\{ |\overline{X} - \mu_0| > c \right\} = \alpha \\ P_{r_{\mu_0}} \left\{ \frac{|\overline{X} - \mu_0|}{\frac{\sigma}{\sqrt{n}}} > \frac{c}{\frac{\sigma}{\sqrt{n}}} \right\} = \alpha \\ P_{r_{\mu_0}} \left\{ |z| > z_{\alpha} \right\} = \alpha \end{array}$$

**Esempio** (5 transimissioni) 
$$n=5$$
  $\overline{X}=9.5$   $H_0: \mu=8$   $\alpha=5\%$ 

Ipotizzando che  $H_0$  sia vera:

$$\frac{|\overline{X} - \mu|}{\frac{\sigma}{\sqrt{n}}} = \frac{|9.5 - 8|}{\frac{2}{\sqrt{5}}} \approx 1.68$$

Se:

 $\alpha = P_r(\text{rifiuto } H_0 \ / \ H_0 \ \text{vera})$ 

 $\alpha \uparrow$  più *"facile"* rifiutare l'ipotesi

 $\alpha \downarrow \text{più "difficile" rifiutare l'ipotesi$ 

### 8.1 Metolodogia alternativa

$$Ts = \frac{\overline{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}} \rightarrow \text{Statistica di test}$$

 $P{\operatorname{\mathsf{-value}}} = \operatorname{\mathsf{probabilit\hat{a}}}$  di ottenere un valore più "anomalo" di quello osservato

Esempio: 
$$X_i \sim \mathcal{N}(\mu, 4)$$

$$n=5$$
  $H_0: \mu=8$   $\overline{X}=8.5$   $H_a: \mu \neq 8$ 

$$\frac{|\overline{X} - \mu_0|}{\frac{\sigma}{\sqrt{n}}} = \frac{|8.5 - 8|}{\frac{2}{\sqrt{5}}} = \frac{\sqrt{5}}{2}0.5 \approx 0.559$$

$$P\{|z|>0.559\}=2P\{z>0.559\}\approx 2\cdot 0.288=0.579 \to \text{P-value}$$

Se 
$$\overline{X}=11.5$$
:

$$\frac{|\overline{X} - \mu_0|}{\frac{\sigma}{\sqrt{n}}} = \frac{|11.5 - 8|}{\frac{2}{\sqrt{5}}} \approx 3.913$$

 $P\{|z|>3.913\}=2P\{z>3.913\}\leq 0.00005 \rightarrow \underline{\text{Rifiuto ipotesi } H_0}$ 

### 8.2 Test di Hp unilaterale

$$H_0: \mu = \mu_0(\mu \le \mu_0) \qquad H_a: \mu > \mu_0$$

$$C = \{(X_1 \dots n) \cdot \overline{X} - \mu_0 > c\}$$

$$P_{r_{\mu_0}}\{\overline{X} - \mu_0 > c\} = P_r\{\frac{\overline{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}} > \frac{c}{\frac{\sigma}{\sqrt{n}}}\} = P_{r_{\mu_0}}\{z > z_a\} = \alpha$$

Statistica test  $rac{\overline{X}-\mu_0}{rac{\sigma}{\sqrt{n}}} \leq z_{lpha}$  accetto

### 8.3 Test di ipotesi

$$\begin{array}{lll} H_0 & H_a & {\rm TS} & {\rm Livello} \ \alpha & {\rm P-Value} \\ \\ \mu = \mu_0 & \frac{\overline{X} - \mu_0}{\sigma/\sqrt{1}} & {\rm Rifiuto} \ H_0 \\ & {\rm se} \ TS > \frac{z\alpha}{2} & 2P(z \geq |TS|) \end{array}$$

### Altre ipotesi

$$\begin{array}{lllll} H_0 & H_a & \text{TS} & \text{Livello } \alpha & \text{P - Value} \\ \\ \mu < \mu_0 & \mu > \mu_0 & \frac{\overline{X} - \mu_0}{\sigma/\sqrt{2}} & H_0 & z_\alpha > TS & P(z \geq TS) \\ \\ \mu \geq \mu_0 & \mu < \mu_0 & // & H_0 & z_\alpha < -TS & P(z \leq TS) \end{array}$$

### 8.4 Uguaglianza media di due popolazioni

$$\begin{array}{lll} X_1\dots X_n \sim \mathcal{N}(\mu_1,\sigma_2^2) & Y_i\dots Y_m \sim \mathcal{N}(\mu_2,\sigma_2^2) \\ \overline{X} = \frac{1}{n}\sum_i^n X_i & \overline{Y} = \frac{1}{m}\sum_i^m Y_i \\ S_x^2 = \frac{1}{n-1}\sum_i (X_i - \overline{X})^2 & S_y^2 = \frac{1}{m-1}\sum_i (Y_i - \overline{Y})^2 \\ & S_p^2 = \frac{(n-1)S_x^2 + (m-1)S_y^2}{n+m} \\ H_0 & H_a & \text{TS} \\ H_0 = \mu_2 & \mu \neq \mu_2 & \frac{\overline{X} - \overline{Y}}{\sqrt{\sigma_{1/n}^2 + \sigma_{2/m}^2}} & \text{Livello } \alpha & \text{P - Value} \\ \mu_1 = \mu_2 & \mu \neq \mu_2 & \frac{\overline{X} - \overline{Y}}{\sqrt{S_p^2(\frac{1}{n} + \frac{1}{m})}} & \text{rif. } |TS| > z_{\frac{\alpha}{2}} & 2P(z \geq |TS|) \\ \mu_1 = \mu_2 & \mu \neq \mu_2 & S_i \in \text{T-student} \end{array}$$

### 4) T-test per coppie di dati Se $X_1$ e $X_2$ NON sono indipendenti

$$W_i = X_i - Y_i$$
 
$$X_i \sim \mathcal{N}(\mu_1, \sigma_1^2)$$
 
$$Y_i \sim \mathcal{N}(\mu_2, \sigma_2^2)$$

#### ES Manutenzione (n guasti) tagliand

$$H_0: \mu_a - \mu_b \ge 0$$
  $\overline{W} = \frac{1}{5}(-7.5 + 2.5 - 2.5 - 3.5 - 1.5) = -2.5$   
 $S_W^2 = \frac{1}{4}(W_i - \overline{W})^2 = 13$ 

$$Ts = \frac{\frac{\overline{W}}{S_W}}{\sqrt{n}} = \frac{\frac{-2.5}{\sqrt{13}}}{\sqrt{5}} = 1.55$$

$$P_r\{T_{n-1} \le Ts\} = \{T_4 \le Ts\}$$

#### 5) Test sulla varianza

$$H_0: \sigma^2 = \sigma_0^2 \quad H_a: \sigma^2 \neq \sigma_0^2$$
$$\frac{(n-1)}{\sigma_0^2} \sim \mathcal{X}_{n-1}^2$$

$$Pr\{\mathcal{X}_{1-\frac{\alpha}{2},n-1}^2 \le \frac{(n-1)s^2}{\sigma_0^2} \le \mathcal{X}_{\frac{\alpha}{2},n-1}^2\} = 1 - \alpha$$

Uguaglianza di varianza

$$X_1 \dots X_n$$
  $Y_1 \dots Y_n$   $H_0: \sigma_x^2 = \sigma_y^2$   $H_a: \sigma_x^2 \neq \sigma_y^2$ 

$$S_x^2 - S_y^2$$
  $Ts = \frac{\frac{S_x^2}{\sigma_x^2}}{\frac{S_y^2}{\sigma_y^2}} = \frac{S_x^2}{S_y^2}$ 

$$\frac{S_x^2}{S_y^2} \sim F_{n-1,m-1} \qquad Pr\{F_{1-\frac{\alpha}{2},n-1,m-1} \leq \frac{S_x^2}{S_y^2} \leq -F_{1-\frac{\alpha}{2},n-1,m-1}\}$$
 Non rifiuto se soddisfa la disuguaglianza

Test parametro Bernoulli (Var discrete.)

$$H_0: p \le p_0 \quad H_a ip > p_0$$

$$p(k) = \binom{n}{k} p^k (1-p)^{n-k}$$
 n campioni (Bernoulli)

Binomiale ~ Gaussiana (quando n è grande)

X n eventi favorevoli

$$\mathbb{E}[X] = np \qquad Var(X) = np(1-p) \quad \mathcal{N}(np, np(1-p))$$

**Esempio** Difetti di fabbricazione:

$$n = 300 \ H_oip \le p_0 \quad p_0 = 2\%$$

X = 10 n difetti

$$\frac{X-np}{\sqrt{nP_0(1-p_0)}} = \frac{10-300\cdot 0.02}{\sqrt{300\cdot 0.02\cdot 0.98}} = 1.65$$

$$Pr\{z > 1.65\} = 0.0495$$

## 8.5 Modelli previsionali

8.5.1 Modelli di regressione previsionale

$$Y_i = \alpha + \beta x_i + e_i$$
  $e_i \sim \mathcal{N}(0, \sigma^2)$ 

Problema 
$$\{x_i, y_i\}_{i=1}^n \quad \alpha, \beta = ?$$

Sum of square -> SS  $\sum_{n=1}^{\infty} T_n(x)$ 

$$SS = \sum_{i=1}^{n} (y_i - \alpha + \beta x_i)^2 Dove B e A \rightarrow var aleatoria$$

$$\begin{cases} \frac{dSS}{dA} = -2\sum_{i=1}^{n} (y_i - A - Bx_i) = 0\\ \frac{dSS}{dB} = -2\sum_{i=1}^{n} (y_i - A - Bx_i)^2 x_i = 0 \end{cases}$$

$$\begin{cases} \sum_{i=1}^{n} y_i = nA + B \sum_{i=1}^{n} x_i \\ \sum_{i=1}^{n} x_i y_i = n \sum_{i=1}^{n} + B \sum_{i=1}^{n} x_i \end{cases}$$
$$A = \frac{1}{n} \sum_{i=1}^{n} y_i - B \frac{1}{n} \sum_{i=1}^{n} x_i = \overline{y} - \beta \overline{x}$$

### 8.5.2 Regressione lineare

$$y = \alpha + \beta x$$
  $e \sim (0,1)$   $y_i = A + \beta x$ 

$$\begin{array}{ll} \mathbb{E}[B] = \beta & \mathbb{E}[A] = \alpha \\ Var[B] = \frac{\sigma^2}{\sum_i x_i^2 - n\overline{x}} & Var[A] = \frac{\sigma^2 \sum_i x_i^2}{n(\sum_i x_i^2 - n\overline{x}^2)} \end{array}$$

$$SS_R = \sum_i (y_i - (A + Bx_i))^2$$
 (Somma dei quadrati dei residui)

$$\frac{SS_R}{\sigma^2} \sim \mathcal{X}_{n-2}^2$$

$$\mathbb{E}[\frac{SS_R}{\sigma^2}] = n - 2 \qquad \qquad \mathbb{E}[\frac{SS_R}{n-2}] = \sigma^2$$

#### MLE :

$$f_{y_1...y_n}(y_1...y_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\sum(y-(\alpha+\beta x_i0))^2/2\sigma^2}$$

$$\mathsf{MSE} = \mathsf{MLE}$$

Notazione

$$S_{xy} = \sum_{i} (x_{i} - \bar{x}) (y_{i} - \bar{y}) = \dots = \sum_{i} x_{i} y_{i} - n\bar{x}\bar{y}$$

$$S_{xx} = \sum_{i} (x_{i} - \bar{x})^{2} = \dots = \sum_{i} x_{i}^{2} - n\bar{x}$$

$$S_{yy} = \sum_{i} (y_{i} - \bar{y})^{2} = \dots = \sum_{i} y_{i}^{2} - n\bar{y}$$
(7)

 $S_{xy}$  (Dispersione di x e y)  $S_{xy}$  (Dispersione di x)  $S_{xy}$  (Dispersione di y)

$$A = \overline{y} - B\overline{x} \qquad B = \frac{S_{xy}}{S_{xx}} \qquad SS_R = \frac{S_{xx}S_{yy} - S_{xy}^2}{S_{xx}}$$

Inferenza su  $eta \quad \frac{B-eta}{\sqrt{\frac{\sigma^2}{S_{xx}}}} \sim \mathcal{N}(0,1) \qquad \frac{SS_R}{\sigma^2} \sim \mathcal{X}_{n-2}^2$ 

$$\frac{\frac{B-\beta}{\sqrt{\frac{\sigma^2}{S_{xx}}}}}{-\sqrt{\frac{SS_R}{j^2(n-2)}}} \sim t_{2-2}$$

$$\begin{split} &\sqrt{\frac{(n-2)S_{xx}}{SS_R}}(B-\beta) \sim t_{n-2} \\ &\beta \in B \pm \sqrt{\frac{SS_R}{(n-2)S_{xx}}} \quad t_{\frac{\alpha}{2},n-2} \to \text{Livello di confidenza} \end{split}$$

$$\text{Inferenza su } \alpha \quad \frac{A-\alpha}{\sqrt{\frac{\sigma^2\sum x_i^2}{nS_{xx}}}} \sim \mathcal{N}(0,1) \qquad \frac{SS_R}{\sigma^2} \sim \mathcal{X}_{n-2}^2$$

coeffieciente della retta:

$$lpha \in A \pm rac{SS_R \sum x_i^2}{\sqrt{n(n-2)S_{xx}}} \sim t_{rac{lpha}{2},n-2} 
ightarrow {
m Livello}$$
 di confidenza

Interferenza su  $\alpha + \beta x_0$ 

$$\mathbb{E}[A + Bx_0] = \mathbb{E}[A] + x_0 \mathbb{E}[B] = \alpha + \beta x_0$$
$$Var(A + Bx_0) = \dots = \sigma^2 \left[\frac{1}{n} + \frac{(\overline{x} - x_0)^2}{S_{xx}}\right]$$

Distribuzione  $A + Bx_0$  ?

$$A + Bx_0 \sim \mathcal{N}(\alpha + \beta x_0, \sigma^2 \left[\frac{1}{n} + \frac{(\overline{x} - x_0)^2}{S_{xx}}\right])$$
 Stima di  $\alpha + \beta x_0$ 

$$\frac{A + Bx_0 - (\alpha + \beta x_0)}{\sqrt{(\frac{1}{n} + \frac{(x_0 - x)^2}{S_{xx}}(\frac{SS_R}{n - 2}))}} \sim t_{n - 2}$$

$$\alpha + \beta x_0 \in A + Bx_0 \pm t_{\frac{\alpha}{n}, n-2} \sqrt{\frac{1}{n} + \frac{(x_0 - \overline{x})^2}{S_{xx}} (\frac{SS_R}{n-2})}$$

Piccolo se i punti sono vicini alla media

### 8.5.3 Regressione Lineare (e non)

$$\{x_i, y_i\}_{i=1}^2 \leftarrow \mathsf{punti} \mathsf{stocastici}$$

Inferenza  $\alpha+\beta x_0=\mathbb{E}[y] o$  non so niente del valore della y in quel punto Inferenza  $y_0=y(x_0)\theta$ 

$$\begin{aligned} &\alpha+\beta x_0\in A+Bx_0\pm t_{\frac{\alpha}{2},n-2}\sqrt{(\frac{1}{n}+\frac{(x_0-\overline{x})^2}{S_{xx}})\frac{SS_R}{n-2}}\\ &\alpha+\beta\mathbf{x_0}\rightarrow \text{II punto }x_0\text{ che sta sulla retta }\alpha+\beta x_0\end{aligned}$$

Inferenza 
$$y_0 = y(x_0) \rightarrow$$
 predittivo

$$y \sim \mathcal{N}(\alpha + \beta x_0, \sigma^2)$$

$$A + Bx_0 \sim \mathcal{N}(\alpha + \beta x_0, \sigma^2(\frac{1}{n} + \frac{(x_0 - \overline{x})^2}{S_{xx}}))$$

$$y_0 - (A + Bx_0) \sim \mathcal{N}(\sigma, \sigma^2(1 + \frac{1}{n} + \frac{(x_0 - \overline{x})^2}{S_{xx}}))$$

$$y_0 = y(x_0) = A + Bx_0 \pm t_{\frac{\alpha}{2}, n-2} \sqrt{(1 + \frac{1}{n} + \frac{(x_0 - \overline{x})^2}{S_{xx}}) \frac{SS_R}{n-2}}$$

#### Coefficiente di determinazione

Definizione: La verifica dei miei valori

Formula generica:  $S_{yy} = \sum_{i=1}^n (y_i - \overline{y})^2 \to \text{dispersione di y}$  La dispersione è data da due fattori:

• Retta (regressione)

#### Rumore

 $SS_R = \sum_{i=1}^n (y_i - (A + Bx_i))^2 \to \text{Dipende dalla porzione non spiegata della retta}$ Utilizzo coefficienti di determinazione:

$$R^{2} = \frac{S_{yy} - SS_{R}}{S_{yy}} = 1 - \frac{SS_{R}}{S_{yy}} \quad 0 \le R^{2} \le 1$$

Se  ${f R^2=1}$  la dispersione è data solo dalla retta *(regressione)* Se  ${f R^2=0}$  la dispersione è data solo dal *rumore* 

La retta è migliore più  $\mathbb{R}^2$  è vicino a  $\mathbf{1}$ 

#### Coefficiente di correlazione

### Formula generica:

$$r = \frac{\sum_i (x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_i (x_i - \overline{x})^2 \sum_i (y_i - \overline{y})^2}} = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$$
 
$$r^2 = \frac{S_{xy}^2}{S_{xx}S_{yy}} = \ldots = 1 - \frac{SS_R}{S_{yy}} \rightarrow \text{Dimostrazione matematica di } R^2$$

Analisi dei residui y-(A+Bx) o verifico tutti gli errori residui Per la non linearità

#### Trasformazione lineare

$$W(t) = ce^{-dt}$$

### Dove ce e -dt sono parametri

 $\log(W(t)) = \log(c) - dt \rightarrow \mathsf{Prob}$ . soluzione al non lineare  $y = \alpha + \beta x$ 

#### Rimedio al caso eteroschedastico

$$y_i = \alpha + \beta x_i + e_i$$
  $e_i \sim \mathcal{N}(0, \sigma_i^2) \rightarrow \text{errore in crescita x}$   $Var(e_i) = \frac{\sigma^2}{W_i} \sum W_i (y - (A + Bx_0))^2$ 

• Regressione lineare multipla

$$-\mathbf{y} = \beta_0 + \beta_1 \mathbf{x}_1 + \beta_2 \mathbf{x}_2 \dots \beta_k \mathbf{x}_k + \mathbf{e}$$
$$-\min \sum_{i} (y_i - (B_0 + B_1 x_{i1} + B_2 x_{i2} + \dots + B_k x_{ik}))^2$$

• Regressione (lineare) polinomiale

$$- y = \beta_0 = \beta_1 x + \beta_2 x^2 + \dots + \beta_k x^k + e$$
$$- \{ \underline{x_i}, y_i \}_{i=1}^n$$

$$\frac{\mathrm{d}}{\mathrm{d}B_0} = 0 = \sum_{i} (y_i - 1 - B_1 x_{i1} + B_2 x_{i2} + \dots + B_k x_{ik})$$

$$\frac{\mathrm{d}}{\mathrm{d}B_1} = 0 = \sum_{i} x_{i1} (y_i - B_0 - B_1 x_{i1} + B_2 x_{i2} + \dots + B_k x_{ik})$$

$$x^t x \underline{\beta} = x^t \underline{y} \Longrightarrow \underline{\beta} = (x^x x)^{-1} x^t \underline{y}$$

### AN.O.VA (analysis of variance)

Analisi delle varianze / estensione del test di ipotesi sulle medie

Esempio voti medi degli anni scolastici

Voti medi. Anno.

2020-2021 lockdown  $\mu_a$ 2021-2022 lockdown parziale  $\mu_b$ 2022-2023 presenza

 $H_0: \mu_a = \mu_b = \mu_c$ 

### 1) stimatore di $\sigma^2$ :

$$\sum_{i=1}^{\infty} \sum_{j=1}^{\infty} \frac{(x_{ij} - \mathbb{E}[x_{ij}])^2}{\sigma^2} = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} \frac{(x_{ij} - \mu_i)^2}{\sigma^2} \sim \mathcal{X}_{m \cdot n}^2$$
$$SS_W = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} \frac{(x_{ij} - x_{i*})^2}{\sigma^2} \sim \mathcal{X}_{m \cdot n - m}^2$$

 $\mu_c$ 

$$\mathbb{E}\left[\frac{SS_w}{\sigma^2}\right] = n \cdot m - m$$

$$\mathbb{E}\left[\frac{SS_w}{nm-m}\right] = \sigma^2$$
 stimatore 1

2) stimatore di  $\sigma^2$  supponendo  $\mu_1=\mu_2=\mu_3=\ldots=\mu_m=\mu$ 

$$n \sum_{i=1}^{m} \frac{(x_{i*} - \mu)^2}{\sigma^2} \sim \mathcal{X}_m^2 \qquad x_{**} = \frac{\sum_{i=1}^{m} \sum_{i=1}^{n} x_{ij}}{m \cdot n}$$

$$SS_b = n \sum_{i=1}^m (x_{i*} - x_{**})^2 \sim \mathcal{X}_{m-1}^2$$
  $\mathbb{E}[\frac{SS_b}{m-1}] = \sigma^2 o$  Stimatore 2

Verifico stimatori

$$Ts = rac{SS_b/m - 1}{SS_W/nm - m} 
ightarrow {
m intorno}$$
 a 1 va bene

**F** Distribution:  $F_{m-1}, mn - m, \alpha$ 

#### ANOVA

Se i gruppi sono uguali :  $n \text{ camp} = n \cdot m$ Se sono diversi :  $n \text{ camp} = \sum_i n_i$ 

Life testing (Misura di affidabilità)

$$x \ge 0$$
 | tempo di vita  $\lambda(t) = \frac{f(t)}{1 - F(t)}$ 

f(t) = Densità di popolazione

 $\lambda(t) = \text{Intensità di rottura (failure rate)}$ 

$$\begin{split} P(x \in (t, t + \triangle t) | x > t) &= \frac{P(x \in (t, t + \triangle t), x > t)}{P(x > t)} \\ &= \frac{P(x \in (t, t + \triangle t))}{P(x > t)} \\ &\approx \frac{F(t) \triangle t}{1 - F(t)} \end{split}$$

#### Intensità di rottura

**Definizione:** Densità condizionale di probabilità che un oggetto funzionante almeno fino a t si guasti "subito dopo"

### Formula generica:

$$\lambda(t) = \frac{F(t)}{1 - F(t)}$$

Se la distribuzione è esponenziale:

$$\lambda(t) = \frac{\lambda e^{-\lambda t}}{1 - 1 + e^{-\lambda t}} = \lambda \rightarrow \text{dove } \lambda \text{ è una costante}$$

Proprietà  $\lambda(t) \Rightarrow F(t)$ 

$$\lambda(s) = \frac{f(s)}{1 - F(s)} = \frac{F'(s)}{1 - F(s)} = \frac{d}{dS} [-\log(1 - F(s))]$$

$$\int_0^t \lambda(s) = -\log(1 - F(s)) + \log(1 - F(s)) = 1 - F(t) = e^{-\int_0^t \lambda(s)ds}$$

**Esempio** Tasso di mortalità di un fumatore  $(\lambda_s)$  e di un <u>non</u> fumatore  $(\lambda_n)$ 

$$\lambda_s(t) = 2\lambda_n(t)$$

$$\begin{split} &= P(\mathsf{Non fumatore di età} \; \mathbf{A} \; \mathsf{vive fino a} \; \mathbf{B}) \\ &= P(\mathsf{Non fumatore vive fino a} \; \mathbf{B} \; | \; \grave{\mathsf{e}} \; \mathsf{vissuto fino} \; \mathbf{A}) \\ &= \frac{P(\mathsf{Non fumatore viva fino a} \; \mathbf{B})}{P(\mathsf{Non fumatore viva fino a} \; \mathbf{A})} \\ &= \frac{1 - F_N(B)}{1 - F_N(A)} \\ &= \frac{e^{-\int_0^B \lambda(t) \; dt}}{e^{-\int_0^A \lambda(t) \; dt}} \end{split}$$

Quindi:

 $P({\sf Non\ fumatore\ di\ eta\ A\ vive\ fino\ a\ B}) = e^{-\int_A^B \lambda(t)\, dt}$ 

Per i non fumatori invece:

 $P({\sf Fumatore\ di\ eta\ {f A}\ vive\ fino\ a\ {f B}}) = e^{-\int_A^B \lambda(t)\, dt} = Ps$ 

Dove  $Ps=(Pn)^2 o$  quindi la probabilità di soppravivenza del fumatore è uguale alla probabilità di soppravivenza del non fumatore al quadrato

Probabilità che un non fumatore arrivi ai 60 anni sapendo che è arrivato ai 50:

$$\lambda_N(t) = \frac{1}{20} \qquad 50 \le t \le 60$$

$$\begin{split} P_N &= e^{-\int_{50}^{60} \frac{1}{20} \, dt} = e^{-\frac{1}{20}(60-50)} = e^{-\frac{1}{2}} \approx 0.607 \approx 61\% \\ P_{\leq}(e^{-\frac{1}{2}})^2 &= e^{-1} \approx 0.368 \approx 37\% \end{split}$$

**Stima di affidabilità** N oggetti che si possono guastare *indipendenti* tra di loro Tempi di vita:  $\lambda e^{-\lambda t}$   $\lambda = \frac{1}{\theta} \Rightarrow \frac{1}{\theta} e^{-\frac{t}{\theta}}$ 

 $\textbf{Dati a disposizione} \quad x_1 \leq x_2 \leq x_3 \leq x_4 = r \quad i_1 = 2, i_2 = 3, i_3 = n, i_4 = 1$ 

Studio la variabile aleatoria  $X_i,\,i_j$  indica quale  $oggetto\,si\,\,\grave{e}\,\,guastato\,$  per j-esimo all'istante  $x_j$ 

(n-r) non si sono guastati  $\Rightarrow$  per questi  $X_i > x_r$ 

$$fx_1, x_2 \dots x_r(x_1, x_2, \dots, x_r) = \prod_{i=1}^{r} \frac{1}{\theta} e^{-\frac{x_j}{\theta}} = \frac{1}{\theta^r} e^{-\frac{\sum_{j=1}^{r} x_j}{\theta}}$$

Ora per i non guasti:

$$\begin{split} P\left(X_j > x_j \text{ con } j \not\in \{i_1, \dots, i_r\}\right) &= \prod_{r+1}^n (1 - F_{X_j}(x_r)) = \left[1 - (1 - e^{\frac{-x_r}{\theta}})\right] \\ &\log L = -r\log \theta - \frac{1}{\theta} \left[\sum_i^r x_i + (n-r)x_r\right] \\ &\frac{d\log}{d\theta} = -\frac{r}{\theta} + \frac{1}{\theta^2} \left[\sum_i^r x_i + (n-r)x_r\right] = 0 \\ &- \theta r + \left[\sum_i^r x_i + (n-r)x_r\right] = 0 \\ &\hat{\theta} &= \frac{\sum_i^r x_i + (n-r)x_r}{r} = \frac{t}{r} = \frac{TTT}{r} \to \text{Total Time Test} \end{split}$$